深入 HTTP 协议以及 Web 运维

—— Web 端运维基础知识

Victor Huang | Mar. 26th, 2022

日录

- HTTP 协议和 Web 浏览器
- Web 运维部分

HTTP 协议和 Web 浏览器

- HTTP/0.9: 单行协议:
 - 请求只能容纳一行,只有 GET 方法。例如 GET /index.html。
 - 响应体只包含文件内容。
- 不足:
 - 没有 HTTP 头机制,无法传递除文件之外的任何信息。
 - 没有状态码机制,不易判断是否出现错误。
 - 无法进行文件上传。

- HTTP/1.0:
 - 加入了HTTP 头机制,拥有了可扩展性。
 - •引入了HTTP状态码,易于查错。
 - 引入了 POST 等方法。
- 不足:
 - 标准制定时歧义较大,实现较为混乱。
 - 一个连接只能进行一次请求和响应。

• HTTP/1.1:

- •加入了连接复用机制,可以在一个TCP连接中收发多个HTTP请求和响应。
- 加入了 HTTP Pipelining, 客户端可以连续发送请求。
- 响应分块、编码控制等等一系列改进。

不足:

- 纯文本协议传输和解析开销相对都偏高,且 HTTP 头无法压缩。
- 请求和响应必须顺序抵达,等待开销较大。

• HTTP/2:

- 全面采用二进制协议,降低了机器传输和解析开销。
- HTTP 头可以被压缩。
- 引入了 Server Push, 服务器可以主动向客户端推送数据。
- 多种优化措施,例如连接的合并。

不足:

● 仍然基于 TCP 连接,受到三次握手的限制,延时较高,且存在队列阻塞的问 题。

- HTTP/3:
 - 改用 UDP 传输,避免了 TCP 握手延时和队列阻塞。
 - 采用 QUIC 连接控制,配合 TLS 1.3 可以实现 0-RTT 连接。
- 不足:
 - UDP 在部分地区易受限制。
 - 客户端、网络设备支持情况目前较差,未来可期。

HTTP的基本性质

- 无状态,有会话
 - HTTP 本身是无状态协议,会话通过 Cookie 保持
- 简单而可扩展
 - HTTP/2 之前的 HTTP 为纯文本协议
 - 通过 HTTP 头的机制,实现各种扩展功能

HTTP重定向

• 301、302、303、307、308 是重定向状态码。

| | 缓存(永久重定向) | 不缓存(临时重定向) |
|------|-----------|------------|
| 转GET | 301 | 302、303 |
| 方法保持 | 308 | 307 |

- 使用 Location 响应头来返回目标地址。
 - 一种返回格式是完整 URL,例如 Location: https://redrock.team/
 - 另一种是返回路径,例如 Location: /foo/

HTTP连接复用

- HTTP/1.1 加入了长连接。
 - Connection 头配置为 keep-alive 时,HTTP 进入长连接状态。服务端发送完响应后不关闭连接。客户端可以在同一个连接内发送请求。
 - 结束连接或明确表示不启用长连接,Connection 头配置为 close。
- HTTP/2 在多个连接的域名可被同一 HTTPS 证书验证时,会自动合并连接来减少连接数,但这在某些情况下可能导致问题。
 - https://www.zhihu.com/question/310263956/answer/601458852

HTTP会话

- HTTP 通过 Cookie 保持会话。
- Cookie 是一种 Key-Value 集合,并附加了一些配置项目。接受 Cookie 的客户端每次请求时带着 Cookie 头发给服务器。
- 服务端可以通过 Set-Cookie 头来设置 Cookie。
 - 例如 Set-Cookie: id=a3fWa; Expires=Wed, 21 Oct 2015 07:28:00 GMT; Secure; HttpOnly
- Cookie 有许多属性,例如上面的:
 - Expires: 设置了 Cookie 的过期时间
 - Secure: 只允许在 HTTPS 下传输
 - HttpOnly: 不允许通过 JavaScript 脚本读取 Cookie。

HTTP会话

- Cookie 可以通过属性限制它被发往哪里:
 - Domain 属性指定了哪些域名可以被发送 Cookie,它包括子域名。即 Domain=redrock.team 允许向 app.redrock.team 发送 Cookie。
 - Path 属性指定了哪些路径可以被发送 Cookie。
 - SameSite 限制跨站发送 Cookie。

- 众所周知,一个网站有大量的资源,对于不同的资源,浏览器的处理方式也应当不同。
- HTTP 头 Content-Type 则表示了资源的类型。例如:
 - HTML 网页是 text/html
 - PNG 图片是 image/png
- 这种文件类型我们称之为 MIME 类型。它的结构就是:
 - 类型/具体类型
- 具体的 MIME 类型介绍: https://developer.mozilla.org/zh-CN/docs/Web/HTTP/Basics_of_HTTP/MIME_types

- Content-Type 头既可以出现在请求中又可以出现在响应中。
 - 对于请求,它表示 POST 数据时请求体的数据格式。
 - 对于表单,通常有两种格式,一种是 application/x-www-form-urlencoded
 - ,另一种是 multipart/form-data。

● 第一种:

```
POST / HTTP/1.1
Host: foo.com
Content-Type: application/x-www-form-urlencoded
Content-Length: 13
say=Hi&to=Mom
```

• 第二种:

```
POST /test.html HTTP/1.1
Host: example.org
Content-Type: multipart/form-data; boundary="boundary"

--boundary
Content-Disposition: form-data; name="field1"

value1
   --boundary
Content-Disposition: form-data; name="field2"; filename="example.txt"

value2
```

- 对于响应,它表示响应体的格式。
- 有时,在 MIME 类型后面,可能会跟着它的编码。
- 我们在下载时可以看到文件的大小,这是由 Content-Length 头控制的。Content-Length 头的值是一个数字,表示传输文件的字节数。
 - Content-Length 头也会在携带 Body 的请求体出现。
- 偶尔,我们希望改变内容的呈现方式,这时 Content-Disposition 头则处理这类问题。
 - 作为响应时,Content-Disposition: attachment 表示强制作为下载,inline 则期望 <u>浏览器尽量不用下载弹框</u>
 - Content-Disposition 还有 filename 属性,可以指定文件名。

- HTTP 有一系列 Accept 的头供客户端传给服务端,以声明其想要的是怎样的数据。
 - Accept-Encoding 头控制期望的数据编码,因此它可以请求是否使用压缩。
 例如使用 Accept-Encoding: gzip, deflate, br 则告诉服务端可以使用 gzip、deflate、br 等压缩算法。
 - Accept 头说明期望的数据格式,例如 Accept: image/png 则期望服务端发 送 PNG 图片。

- HTTP 具有断点续传的能力。
 - Range 头可以供客户端指定请求的数据范围,格式是

Range: (单位=起始)-[终止(闭区间)]

 服务器收到后,断点续传的内容会返回状态码 206 Partial Content,并携带 Content-Range 头表示当前传输的范围。

Content-Range: 单位 起始-终止(闭区间)/总长度

- 如果终止范围超出文件长度,则认为请求不合法,返回 416 Requested Range Not Satisfiable。
- 如果终止范围小于起始范围,传输整个文件返回 200。
- 例如 Range=-114 这一类请求头,表示获取文件最后的 114 个字节。

- HTTP 还具有条件请求的能力。为了减少不必要的数据传输,客户端可以携带对本地缓存资源的描述,若资源没有更改则无需传输。
 - 服务端返回资源时,可以在头部附带 Last-Modified 头表示最后一次修改的时间,或者 ETag 来表示文件的"实体值",作为资源当前状态的唯一描述。
 - 客户端请求时,可以带上 If-Modified-Since 头或 If-Not-Match 头,分别对应 Last-Modified 和 ETag。
 - 如果服务端的资源发生变更,则 200 返回新的资源并更新上述头。否则,返回 304 Not Modified 告诉客户端无需更改并不传输资源。
- HTTP 也支持控制客户端缓存。
 - Cache-Control 头决定了缓存如何进行控制。
 - https://developer.mozilla.org/zh-CN/docs/Web/HTTP/Headers/Cache-Control

HTTP Referer

- 在浏览器中,用户从链接打开网页以及页面内引入资源时,会带上 Referer 表明来源。
- 通常,可以通过 Referer 统计用户的来源,也可以通过 Referer 限制来防盗链。
- Referer 其实是一个错误拼写,正确的拼写是 Referrer。但 Referer 这个拼写错 误在被应用需求后才被发现,为了兼容现有实现,Referer 被将错就错地纳入了 标准。
 - 但在 Web 浏览器的 JavaScript 中,访问 Referer 采用的是 document.referrer,一定程度上避免了该问题的进一步传播。

HTTP验证

• 访问被保护的资源时,对于尚未授权的客户端服务器返回 401 Unauthorized,同时返回 WWW-Authenticate 头表示支持的验证方式。

WWW-Authenticate: 类型 额外参数

• 客户端携带 Authorization 头,Authorization 头中包含授权信息。

Authorization: 类型 授权字符串

- 目前最常见的验证方式有两种:
 - HTTP 基本验证
 - Authorization 头携带 Basic "用户名:密码"的base64编码 格式
 - Bearer 令牌验证
 - Authorization 头携带 Bearer Token 格式

同源策略和跨域资源共享

- 随着 Web 技术的发展,网页可以通过 JavaScript 进行异步请求访问各种资源。但是如果允许发送任意请求可能会存在安全问题。
- 因此浏览器进行了"同源策略"。
 - https://developer.mozilla.org/zh-CN/docs/Web/Security/Sameorigin_policy
- 但现实业务中,我们不太可能只从同源加载资源。因此为了让资源可以安全地 跨域加载,跨域资源共享(CORS)被提出。
 - https://developer.mozilla.org/zh-CN/docs/Web/HTTP/CORS

同源策略和跨域资源共享

- CORS 预检请求:
 - 使用 OPTIONS 方法。
 - 携带 Origin。
 - 携带 Access-Control-Request-Method 和 Access-Control-Request-Headers
- CORS 预检响应:
 - 返回 204 No Content。
 - Access-Control-Allow-Origin: 允许的源
 - Access-Control-Allow-Methods: 允许的方法
 - Access-Control-Allow-Headers: 允许携带的头
 - Access-Control-Max-Age: 以上信息的客户端缓存时间

WebSocket

- HTTP 归根结底还是必须由客户端发起请求,这就导致服务器难以主动向客户端 推送消息。
- 因此如果遇到类似聊天室或在线游戏等状态实时变化的场景,单纯的 HTTP 便有些难过,常用方式有:
 - 轮询:不断发起请求向服务器询问是否有新的内容,代价是带来了巨大的并 发压力。
 - 长连接:发起连接后服务器不返回数据,直至有新的内容。但这种方式仍然不能做到连续推送数据。
- 因此,为了解决这个问题,WebSocket 出现了。WebSocket 是一个类似TCP的全双工协议,双方可以自由收发数据。

WebSocket

- WebSocket 在握手阶段使用 HTTP 协议,但完成握手后就仅仅是使用 HTTP 所建立的连接来传输数据,和 HTTP 协议再无关联。
- WebSocket 连接建立的过程:
 - 客户端请求服务器,携带头部如下:
 - Connection: upgrade // 表示升级协议
 - Upgrade: websocket // 表示升级到 WebSocket
 - Sec-WebSocket-Version: 13 // 表示使用的 WebSocket 版本
 - Sec-WebSocket-Key: 一段随机生成的密钥

WebSocket

- 服务器返回 101 Switching Protocols, 并返回以下头。
 - Connection: Upgrade
 - Upgrade: websocket
 - Sec-WebSocket-Accept: 从客户端 Sec-WebSocket-Key 计算得
- 之后便建立起了全双工通信。

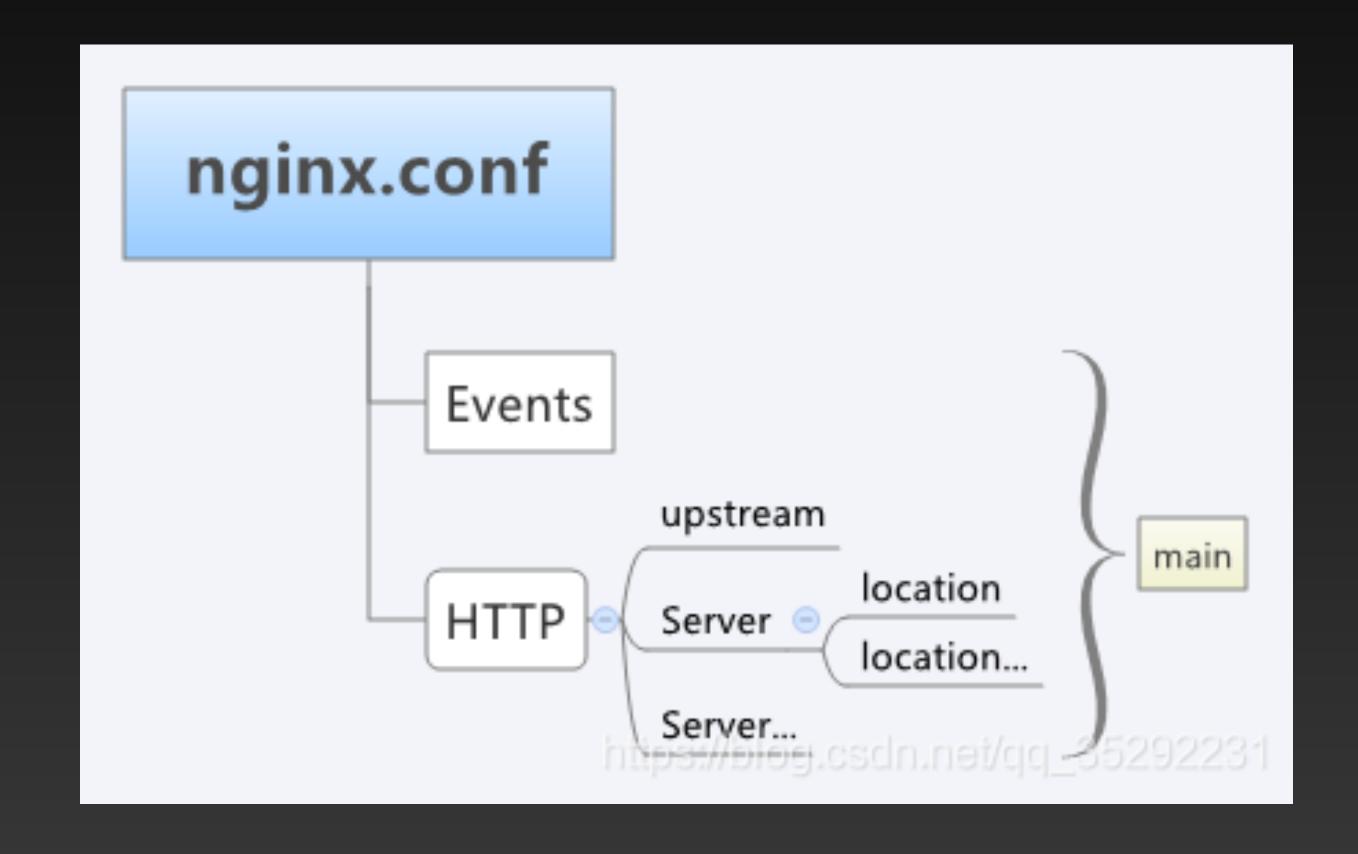
Web运维部分

反向代理

- 反向代理:作为入口接受用户请求,并把请求转发到真正的后端。在反向代理 过程中可以对请求、响应进行修改。
- 我们接下来将会以 Nginx 为例进行讲解。Nginx 是一个优秀的 web 服务器和反向代理。

Nginx

• Nginx 的配置文件以 nginx.conf 为入口。结构大概如下:



虚拟主机

• Nginx 的一个站点称为一个虚拟主机。

```
server {
   listen 80;
   server_name portainer.lyoi.cc;
   location / {
        proxy_pass http://127.0.0.1:20171;
        proxy_redirect
                            off;
        proxy_set_header
                                               $http_host;
                            Host
                            X-Forwarded-Host
                                               $http_host;
        proxy_set_header
                           X-Real-IP
                                               $remote_addr;
        proxy_set_header
                                               $proxy_add_x_forwarded_for;
                            X-Forwarded-For
        proxy_set_header
        proxy_set_header
                            Upgrade
                                               $http_upgrade;
                            Connection
                                               $connection_upgrade;
        proxy_set_header
        proxy_http_version 1.1;
```

- 以上是一个简单的反向代理的虚拟主机。
 - \$ 开头的在 nginx 中称为变量。
 - nginx 有一些自带变量,你也可以自行设置变量。
 - HTTP 头可以通过 \$http_头名 来获取,其中 替换为_

Location 匹幣

| 模式 | 含义 | |
|---------------------|--|--|
| location = /uri | = 表示精确匹配,只有完全匹配上才能生效 | |
| location ^~ /uri | ^~ 开头对URL路径进行前缀匹配,并且在正则之前。 | |
| location ~ pattern | ~ 开头表示区分大小写的正则匹配 | |
| location ~* pattern | ~* 开头表示不区分大小写的正则匹配 | |
| location /uri | 不带任何修饰符,也表示前缀匹配,但是在正则匹配之后 | |
| location / | 通用匹配,任何未匹配到其它 location 的请求都会匹配到,相当于 switch 中的 default | |

如何在反代下获取访客IP

- 在 CDN 或反代后面,我们得到的访客 IP 是代理的 IP。
- 我们通常使用 X-Forwarded-For header 来获取访客 IP。
 - X-Forwarded-For 每经过一个代理便会被追加一次。
 - 它的格式: X-Forwarded-For: client, proxy1, proxy2
- 其它 header 例如 X-Real-IP 也可以用于传递 IP 信息。
- Nginx的 Real IP 模块经过配置后,可以从 X-Forwarded-For 中递归提取 IP。
 - set_real_ip_from CIDR: 信任来自这些主机的转发 IP
 - real_ip_header 指定使用哪个 header
 - real_ip_recursive on/off: 指定是否递归提取 X-Forwarded-For
- 扩展: X-Forwarded-Proto 通常被定义为访客使用的协议(http/https)

其它讲解内容清单

- Map 变量
- 多 upstream
- rewrite

ACME

- Let's Encrypt 提出了 ACME 来自动签发 SSL 证书。
- ACME 协议支持的几种验证方式:
 - HTTP-01 验证方式:
 - CA 提供一个 token 和 fingerprint,然后试图访问你的网站的以下地址,验证指纹是否匹配
 - /.well-known/acme-challenge/<TOKEN>
 - 这种方式不能签发通配符的泛域名证书。
 - TLS-ALPN-01 验证方式:
 - 目前应用不广泛,使用 TLS 握手时的 ALPN 字段验证。

ACME

- DNS-01 验证方式:
 - 通过验证 _acme-challenge.<YOUR_DOMAIN> 的 TXT 记录来证明域名的 所有权。
 - 允许使用 CNAME, 这被称为 DNS Alias 模式。
 - 可以签发泛域名的通配符证书。
- 常用工具: certbot、acme.sh 等

作业

- Lv0. 自行练习 nginx 使用,部署一个基于 websocket 的服务,例如 jupyterlab。
- Lv1. 写一个类似 https://cors-container.herokuapp.com 的 CORS 代理,用于解决后端没有提供跨域的情况。
- Lv2. 自己写一个 http server, 加分项是支持 304 条件请求。

- 尽力去做,不设强制要求。
- 加入 GitHub Classroom: https://classroom.github.com/a/8RZ7Lj7K